


OSNOVE UMETNE INTELLIGENCE

2018/19

ocenjevanje učenja
naivni Bayes

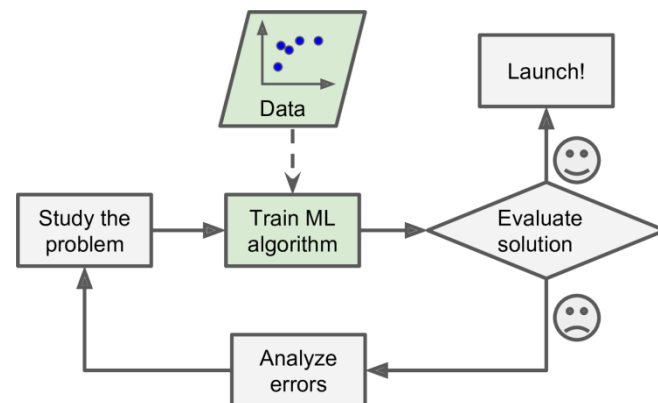
Pregled





- strojno učenje
 - ocenjevanje učenja
 - naivni Bayesov klasifikator
 - nomogrami za naivni Bayes

Ocenjevanje učenja

- kriteriji za ocenjevanje hipotez:
 - točnost (angl. *accuracy*)
 - kompleksnost (angl. *complexity*)
 - razumljivost (angl. *comprehensibility*) – subjektivni kriterij
- ocenjevanje točnosti:
 - na **učnih** podatkih (angl. *training set, learning set*)
 - na **testnih** podatkih (angl. *testing set, test set*)
 - izločimo del učnih podatkov, s katerimi simuliramo ne-videne podatke
 - želimo si, da je testna množica reprezentativna za nove podatke
 - uporabimo lahko **intervale zaupanja** v oceno uspešnosti na testni množici, ki upoštevajo število testnih primerov
 - na **novih** (ne-videnih) podatkih (angl. *new data, unseen data*)
 - na njih bo naučeni sistem dejansko deloval



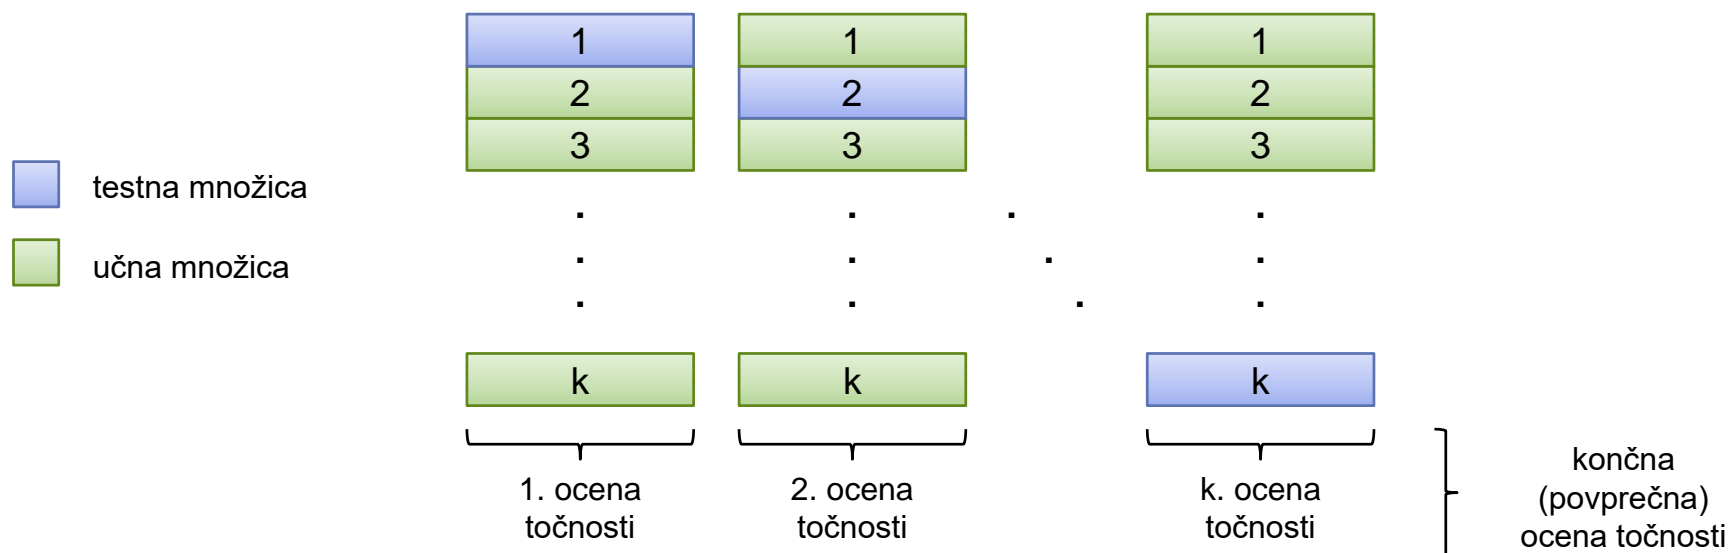
Ocenjevanje učenja



- nasprotujoča si cilja:
 - potrebujemo čim več podatkov za **uspešno učenje**
 - potrebujemo čim več podatkov za **zanesljivo ocenjevanje točnosti** (večje število testnih primerov nam daje ožji interval zaupanja v oceno točnosti)
- rešitev:
 - kadar je učnih podatkov dovolj, lahko izločimo **testno množico** (angl. *holdout test set*)
 - alternativa: **večkratne delitve** na učno in testno množico
- različni načini **vzorčenja testnih primerov**:
 - naključno, nenaključno (npr. prečno preverjanje)
 - poljubno ali stratificirano (zagotovimo enako porazdelitev razredov kot v učni množici)


Prečno preverjanje

- poseben primer večkratnega učenja in testiranja
- k-kratno prečno preverjanje (angl. *k-fold cross-validation*):
 - celo učno množico razbij na k disjunktih podmnožic
 - za vsako od k podmnožic:
 - uporabi množico kot testno množico
 - uporabi preostalih $k-1$ množic kot učno množico
 - povpreči dobljenih k ocen točnosti v končno oceno




Prečno preverjanje

- v praksi najpogosteje: $k=10$ (10-kratno prečno preverjanje)
- vplive izbranega razbitja podatkov na podmnožice lahko zmanjšamo tako, da tudi prečno preverjanje večkrat (npr. 10x) ponovimo (torej $10 \times 10 = 100$ izvajanj učnega algoritma) in rezultate povprečimo
- poseben primer prečnega preverjanja je metoda **izloči enega** (angl. leave-one-out, LOO)
 - k je enak številu primerov (vsaka testna množica ima samo en primer)
 - najbolj stabilna ocena glede učinkov razbitja na podmnožice
 - časovno zelo zamudno, primerno za manjše množice
- iz meritev na vseh podmnožicah je možno izračunati tudi varianco/ intervale zaupanja



Pregled



- strojno učenje
 - ocenjevanje učenja
 - naivni Bayesov klasifikator
 - nomogrami za naivni Bayes

Naivni Bayesov klasifikator

- Thomas Bayes, 1702 – 1761
- opomnik iz teorije o verjetnosti:


$$P(AB) = P(A|B) \cdot P(B)$$

$$P(AB) = P(B|A) \cdot P(A)$$

$$P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}$$

Bayesovo pravilo

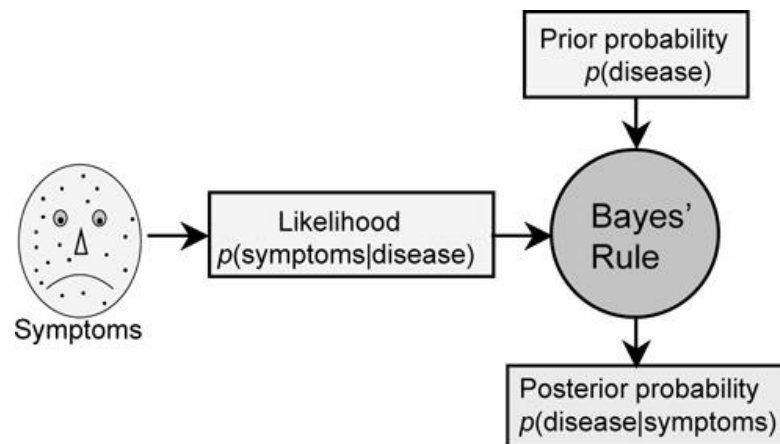


Naivni Bayesov klasifikator

- aplikacija v medicini:


$$P(\text{hipoteza}|\text{opažanje}) = \frac{P(\text{opažanje}|\text{hipoteza}) \cdot P(\text{hipoteza})}{P(\text{opažanje})}$$

- zdravniki razpolagajo z vzročno in statistično informacijo:
 - verjetnost izraženih simptomov pri neki bolezni - $P(\text{opažanje}|\text{hipoteza})$
 - verjetnost določene bolezni - $P(\text{hipoteza})$
 - verjetnost določenega simptoma - $P(\text{opažanje})$
- Bayesovo pravilo nam izraža **diagnostično pogojno verjetnost** $P(\text{hipoteza}|\text{opažanje})$ na podlagi **vzročne pogojne verjetnosti** $P(\text{opažanje}|\text{hipoteza})$



Vaja

- dve vrsti vrečk s frnikulami:
 - 4 vrečke tipa A (vsaka 5 črnih, 15 belih frnikul)
 - 1 vrečka tipa B (16 črnih, 4 bele frnikule)
- možna vprašanja:
 - Kakšna je verjetnost, da je to vrečka tipa B?
 $P(B) = ?$
 - Kakšna je verjetnost, da naključno izberemo črno frnikulo, če izbiramo iz vrečke tipa B?
 $P(\check{C}|B) = ?$
 - Naključno izberemo eno izmed vrečk in iz nje naključno izberemo frnikulo. Kakšna je verjetnost, da smo izbrali črno frnikulo iz vrečke tipa B?
 $P(B\check{C}) = P(B) \cdot P(\check{C}|B) = ?$
 - Naključno izberemo eno izmed vrečk in iz nje naključno izberemo frnikulo. Kakšna je verjetnost, da smo izbrali črno frnikulo?
 $P(\check{C}) = P(B) \cdot P(\check{C}|B) + P(A) \cdot P(\check{C}|A)$



Vaja

- Ena vrečka ima poškodovan ovoj tako, da se skozi njega vidi črna frnikula. Kakšna je verjetnost, da je to vrečka tipa B?
 $P(B|\check{C}) = ?$
- B = hipoteza, Č = evidenca, opažanje
- verjetnost $P(B|\check{C})$ lahko določimo iz drugih bolj očitnih verjetnosti z Bayesovo formulo:

$$P(B|\check{C}) = \frac{P(B) \cdot P(\check{C}|B)}{P(\check{C})}$$

- $P(B) = \frac{1}{5} = 0,2$
 $P(\check{C}|B) = \frac{16}{20} = 0,8$
 $P(\check{C}) = \frac{4 \cdot 5 + 1 \cdot 16}{5 \cdot 20} = 0,444$
- $P(B|\check{C}) = \frac{0,2 \cdot 0,8}{0,444} = 0,360$

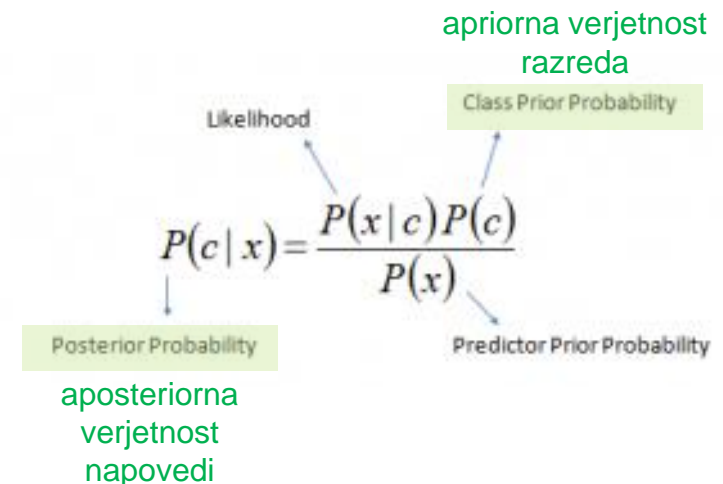
dve vrsti vrečk s frnikulami:

- 4 vrečke tipa A (vsaka 5 črnih, 15 belih frnikul)
- 1 vrečka tipa B (16 črnih, 4 bele frnikule)

Naivni Bayes v strojnem učenju

- evidenca → atributi
hipoteza → razred
- zanima nas, kakšna je verjetnost razreda C pri podanih vrednostih atributov $A_1 = X_1, A_2 = X_2, \dots, A_n = X_n$:

$$P(C|X_1X_2 \dots X_n) = \frac{P(C) \cdot P(X_1X_2 \dots X_n|C)}{P(X_1X_2 \dots X_n)}$$



Naivni Bayes v strojnem učenju

$$P(C|X_1X_2 \dots X_n) = \frac{P(C) \cdot P(X_1X_2 \dots X_n|C)}{P(X_1X_2 \dots X_n)}$$

- $P(X_1X_2 \dots X_n|C) = P(X_1|C) \cdot P(X_2 \dots X_n|X_1C) =$
 $= P(X_1|C) \cdot P(X_2|X_1C) \cdot P(X_3 \dots X_n|X_1X_2C) =$
 $= P(X_1|C) \cdot P(X_2|X_1C) \cdot P(X_3|X_1X_2C) \cdot \dots \cdot P(X_n|X_1X_2 \dots X_{n-1}C)$
- $P(X_1X_2 \dots X_n) = P(X_1|X_2 \dots X_n) \cdot P(X_2|X_3 \dots X_n) \cdot \dots \cdot P(X_{n-1}|X_n) \cdot P(X_n)$
- potrebujemo veliko število pogojnih verjetnosti, katerih poznavanje je v praksi težavno
- število kombinacij pogojnih verjetnosti je glede na zaloge vrednosti atributov $X_1X_2 \dots X_n$ eksponentno
- praktična rešitev: naivni Bayesov klasifikator

Naivni Bayes v strojnem učenju

- predpostavimo, da so atributi med seboj **verjetnostno neodvisni** in poenostavimo:

$$P(X_1 X_2 \dots X_n | C) = P(X_1 | C) \cdot P(X_2 | X_1 C) \cdot \dots \cdot P(X_n | X_1 X_2 \dots X_{n-1} C)$$

$$P(X_1 X_2 \dots X_n) = P(X_1 | X_2 \dots X_n) \cdot P(X_2 | X_3 \dots X_n) \cdot \dots \cdot P(X_{n-1} | X_n) \cdot P(X_n)$$



$$P(X_1 X_2 \dots X_n | C) \approx P(X_1 | C) \cdot P(X_2 | C) \cdot \dots \cdot P(X_n | C)$$

$$P(X_1 X_2 \dots X_n) \approx P(X_1) \cdot P(X_2) \cdot \dots \cdot P(X_{n-1}) \cdot P(X_n)$$

- približki so dobri, če so atributi med seboj dovolj neodvisni
- velja torej:

$$P(C | X_1 X_2 \dots X_n) = \frac{P(C) \cdot P(X_1 X_2 \dots X_n | C)}{P(X_1 X_2 \dots X_n)} = \frac{P(C) \cdot \prod_i P(X_i | C)}{\prod_i P(X_i)}$$

konstanten člen, ki je neodvisen od ciljne spremenljivke
(če opazujemo samo relativne velikosti napovedi različnih
razredov, ga lahko izpustimo)



Naivni Bayes v strojnem učenju

- Bayesov klasifikator: primer **klasificiramo v razred, ki je najbolj verjeten**:

$$h(X_1 X_2 \dots X_n) = \operatorname{argmax}_k P(C_k) \cdot \prod_{i=1}^n P(X_i | C_k)$$

- **učenje**: ocenimo verjetnosti $P(C_k)$ in $P(X_i | C_k)$ za vse razrede C_k in vrednosti atributov X_i
- **napovedovanje**: uporabimo zgornjo enačbo za napovedovanje razreda novim primerom
- *opomba: s poenostavitvijo formule in izpustitvijo imenovalca izgubimo verjetnostno interpretacijo (verjetnosti razredov se ne seštevajo več v 1). Problem rešujemo npr. z normalizacijo rezultatov.*

Primer

- Zajeli smo podatke za 1000 sadežev, ki so lahko bodisi: *banana*, *pomaranča* ali *drugi sadež* (= vrednosti **razreda**). Za vsakega izmed sadežov smo izmerili, ali je *podolgovat*, *sladek* in *rumen* (= **atributi**). Meritve smo zapisali v tabelo:

sadež	podolgovat		sladek		rumen		skupaj
	da	ne	da	ne	da	ne	
banana	400	100	350	150	450	50	500
pomaranča	0	300	150	150	300	0	300
drugo	100	100	150	50	50	150	200
	500	500	650	350	800	200	1000

- iz tabele lahko razberemo različne verjetnosti, npr.:
 - verjetnosti razredov: $P(banana) = \frac{500}{1000} = 0,5$, $P(pomaranča) = 0,3$, $P(drugo) = 0,2$
 - pogojne verjetnosti: $P(dolg|banana) = \frac{4}{5} = 0,8$
 $P(sladek|banana) = 0,7$
 $P(rumen|banana) = 0,9$

Primer

sadež	podolgovat		sladek		rumen		skupaj
	da	ne	da	ne	da	ne	
banana	400	100	350	150	450	50	500
pomaranča	0	300	150	150	300	0	300
drugo	100	100	150	50	50	150	200
	500	500	650	350	800	200	1000

- Imamo sadež, ki ni podolgovat, ni sladek, je pa rumen. Kateri sadež je to?

$$\begin{aligned}
 &P(banana|neP, neS, daR) \\
 &= P(banana) \cdot P(neP|banana) \cdot P(neS|banana) \cdot P(daR|banana) = \\
 &= \frac{500}{1000} \cdot \frac{100}{500} \cdot \frac{150}{500} \cdot \frac{450}{500} = 0,5 \cdot 0,2 \cdot 0,3 \cdot 0,9 = 0,027
 \end{aligned}$$

$$P(pomaranča|neP, neS, daR) = 0,3 \cdot 1 \cdot 0,5 \cdot 1 = 0,15 \quad \leftarrow$$

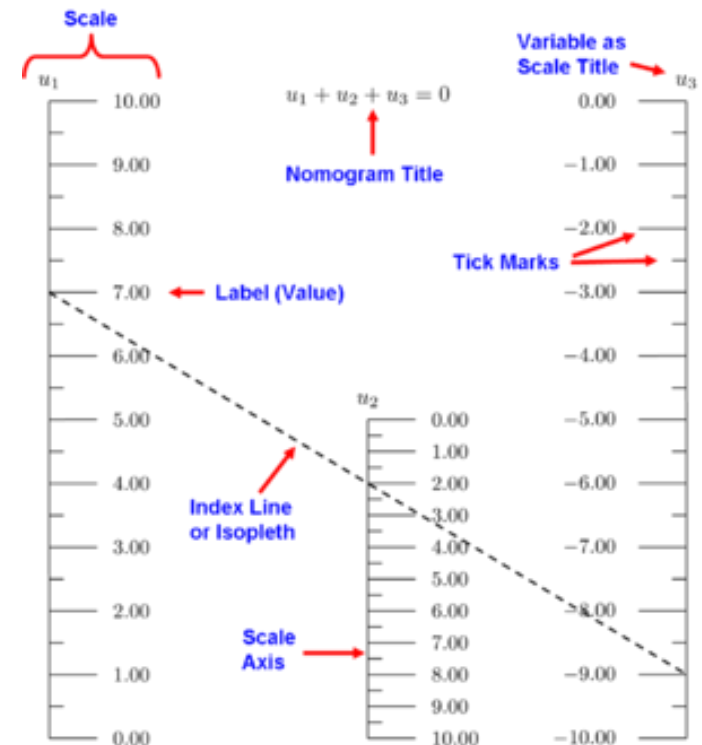
ta sadež je
najverjetneje
pomaranča

$$P(drugo|neP, neS, daR) = 0,2 \cdot 0,5 \cdot 0,25 \cdot 0,25 = 0,00625$$




Nomogrammi

- pristop za vizualizacijo naivnega Bayesovega modela
- prikazuje:
 - pomembnost posameznih vrednosti vsakega atributa na ciljni razred
 - pomembnost posameznih atributov na ciljni razred
 - vizualno razlago napovedanih verjetnosti (brez kalkulatorja)
- "nomogram":
 - je *grafična upodobitev numeričnih odnosov med spremenljivkami*
 - omogoča uporabniku grafično pridobiti rezultat brez računanja
- uporaba:
 - matematika (iskanje vrednosti funkcij)
 - zdravniki v medicini (napovedovanje bolezni – npr. infarkta ali raka na podlagi vhodnih atributov)



Primer - ideja



- vsaka vrednost atributa doprinaša določeno število točk k ciljnemu razredu
- točke vseh vrednosti atributov seštejemo v skupno vsoto točk, ki je povezana z verjetnostjo ciljnega razreda
- razpon posameznih točk vsakega atributa govori o pomembnosti atributa za napovedovanje ciljnega razreda (zgoraj urejeni od najbolj do najmanj pomembnega)


Izračun nomograma

- verjetje razreda pri naivnem Bayesu:

$$h(C|X_1X_2 \dots X_n) = P(C) \cdot \prod_{i=1}^n P(X_i|C)$$

- na zgornjem pravilu uporabimo logistično funkcijo (verjetnosti z intervala $[0,1]$ preslikamo na interval $[-\infty, \infty]$, uporabimo logaritme)

$$\text{logit } P = \log \frac{P}{1-P}$$



- $$\begin{aligned} \text{logit } h(C|X_1X_2 \dots X_n) &= \log \frac{P(C) \cdot \prod_{i=1}^n P(X_i|C)}{1 - P(C) \cdot \prod_{i=1}^n P(X_i|C)} = \log \frac{P(C) \cdot \prod_{i=1}^n P(X_i|C)}{P(\bar{C}) \cdot \prod_{i=1}^n P(X_i|\bar{C})} = \log \frac{P(C)}{P(\bar{C})} + \log \frac{\prod_{i=1}^n P(X_i|C)}{\prod_{i=1}^n P(X_i|\bar{C})} \\ &= \text{logit } P(C) + \sum_i \log \frac{P(X_i|C)}{P(X_i|\bar{C})} \end{aligned}$$

razmerje verjetja
(odds ratio)

Izračun nomograma

- $\text{logit } P(C) + \sum_i \log \frac{P(X_i|C)}{P(X_i|\bar{C})} = \text{logit } P(C) + \sum_i \log OR(X_i)$

razmerje verjetja (odds ratio)

- edino razmerje verjetja je odvisno od vrednosti atributov X_i , torej ga lahko uporabimo za "točkovanje" doprinosa atributa:

$$\text{točke}(C|X_i) = \log OR(X_i) = \log \frac{P(X_i|C)}{P(X_i|\bar{C})}$$

- skupno število točk za verjetnost celotnega primera:

$$\text{točke}(C|X_1 X_2 \dots X_n) = \sum_i \log OR(X_i) = \sum_i \log \frac{P(X_i|C)}{P(X_i|\bar{C})}$$

- Kako izračunati $OR(X_i)$? Po Bayesovem pravilu (znova) velja:

$$\frac{P(X_i|C)}{P(X_i|\bar{C})} = \frac{\frac{P(C|X_i) \cdot P(X_i)}{P(C)}}{\frac{P(\bar{C}|X_i) \cdot P(X_i)}{P(\bar{C})}} = \frac{\frac{P(C|X_i)}{P(C)}}{\frac{P(\bar{C}|X_i)}{P(\bar{C})}} = \frac{\frac{P(C|X_i)}{P(\bar{C}|X_i)}}{\frac{P(C)}{P(\bar{C})}}$$

Primer

- učna množica titanic, 2201 učnih primerov (711 preživelih – razred YES, 1490 umrlih – razred NO)

atribut	vrednost	razred = YES	razred = NO
status	first	203	122
	second	118	167
	third	178	528
	crew	212	673
age	adult	654	1438
	child	57	52
sex	male	367	1364
	female	344	126
razred		711	1490

- Kako konstruiramo nomogram?
- Kako lahko vizualiziramo odločitev za **odraslega moškega**, ki je potoval v **drugem** razredu?


Konstrukcija nomograma

$$\text{točke}(\text{yes}|\text{status} = \text{first}) = \log \frac{\frac{P(\text{first}|\text{yes})}{P(\text{first}|\text{no})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{203}{122}}{\frac{711}{1490}} = \log \frac{1,66}{0,48} = 1,25$$

$$\text{točke}(\text{yes}|\text{status} = \text{second}) = \log \frac{\frac{P(\text{second}|\text{yes})}{P(\text{second}|\text{no})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{118}{167}}{\frac{711}{1490}} = \log \frac{0,71}{0,48} = 0,39$$

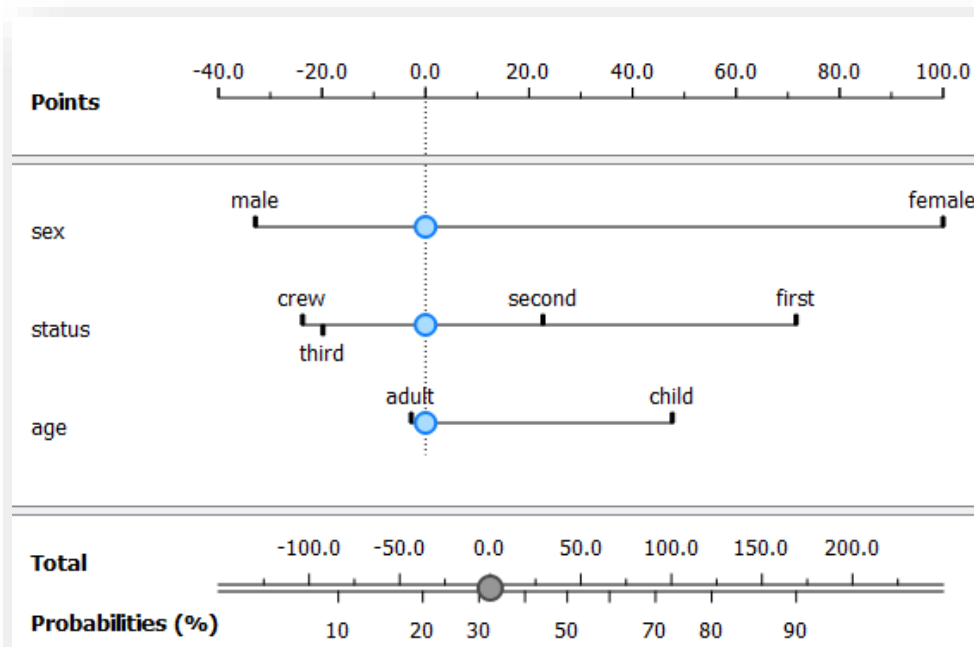
$$\text{točke}(\text{yes}|\text{status} = \text{third}) = \log \frac{\frac{P(\text{third}|\text{yes})}{P(\text{third}|\text{no})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{178}{528}}{\frac{711}{1490}} = \log \frac{0,34}{0,48} = -0,35$$

$$\text{točke}(\text{yes}|\text{status} = \text{crew}) = \log \frac{\frac{P(\text{crew}|\text{yes})}{P(\text{crew}|\text{no})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{212}{673}}{\frac{711}{1490}} = \log \frac{0,32}{0,48} = -0,42$$



Konstrukcija nomograma

- osi ostalih atributov poravnamo glede na ničelno vrednost prispevka atributa
- prikažemo lahko tudi skupno skalo za celotno napoved (vsoto točk)
- točke posameznih vrednosti atributov (log OR) lahko skaliramo v skalo točk, kjer s 100 točkami predstavimo prispevek največje vrednosti atributa
- skupne točke lahko preslikamo nazaj v verjetnosti*



← preslikane točke

← skupna vsota točk

← preslikava v verjetnosti

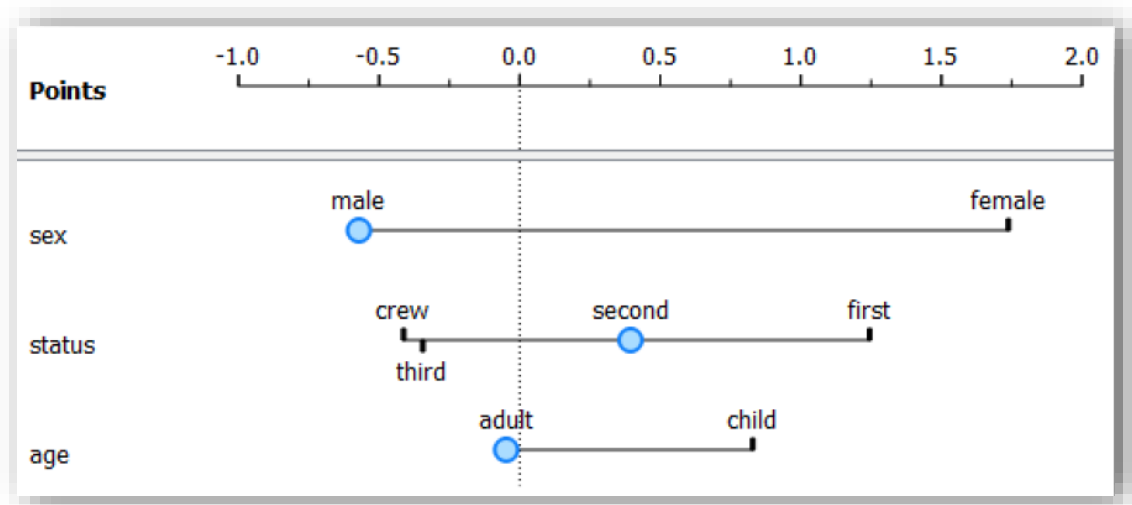
Primer

- Kako lahko pojasnimo odločitev, da je **odrasli moški**, ki je potoval v **drugem** razredu, **preživel**?

$$\text{točke}(\text{yes} | \text{age} = \text{adult}) = \log \frac{\frac{P(\text{adult} | \text{yes})}{P(\text{adult} | \text{no})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{654}{711}}{\frac{1438}{1490}} = \log \frac{0,45}{0,48} = -0,05$$


$$\text{točke}(\text{yes} | \text{sex} = \text{male}) = \log \frac{\frac{P(\text{male} | \text{yes})}{P(\text{male} | \text{no})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{367}{711}}{\frac{1364}{1490}} = \log \frac{0,27}{0,48} = -0,57$$

$$\text{točke}(\text{yes} | \text{status} = \text{second}) = \log \frac{\frac{P(\text{second} | \text{yes})}{P(\text{second} | \text{no})}}{\frac{P(\text{yes})}{P(\text{no})}} = \log \frac{\frac{118}{711}}{\frac{167}{1490}} = \log \frac{0,71}{0,48} = 0,39$$



Primer

- Kako lahko pojasnimo odločitev, da je **odrasli moški**, ki je potoval v **drugem** razredu, **preživel**?
- $točke(yes|adult, male, second) = -0,05 - 0,57 + 0,39 = -0,23$





Nenadzorovano učenje