


OSNOVE UMETNE INTELIGENCE 2018/19

razporejanje opravil

*verjetnostno sklepanje
z bayesovskimi mrežami*

© Zoran Bosnić

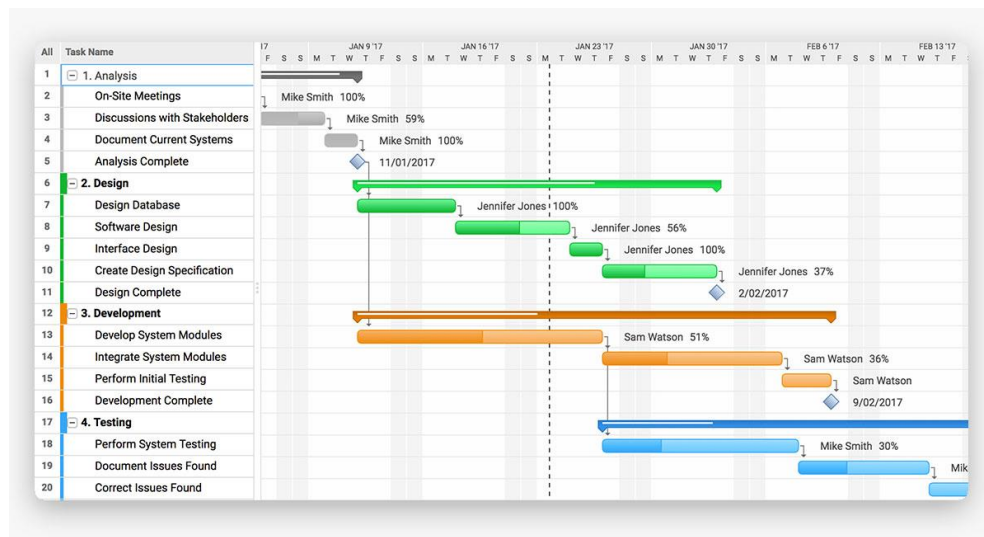
Pregled



- planiranje
 - planiranje s "klasičnim" preiskovanjem prostora stanj
 - planiranje s sredstvi in cilji
 - planiranje z regresiranjem ciljev
 - razporejanje opravil
- bayesovske mreže
 - definicija
 - odvisnosti v bayesovski mreži
 - neodvisnosti v bayesovski mreži
 - verjetnostno sklepanje
 - ekvivalenca bayesovskih mrež

Planiranje in razporejanje opravil

- do sedaj (klasično planiranje): **kaj narediti** in v kakšnem **vrstnem redu**
- pristopi:
 - planiranje kot preiskovanje prostora stanj
 - planiranje s sredstvi in cilji
 - planiranje z regresiranjem ciljev skozi akcije
- v realnosti imamo številne **dodatne omejitve**:
 - časovne omejitve (začetki aktivnosti, trajanja aktivnosti, roki zaključkov)
 - resursi (omejeno število procesorjev, kadra, bencina, denarja, surovin, ...)



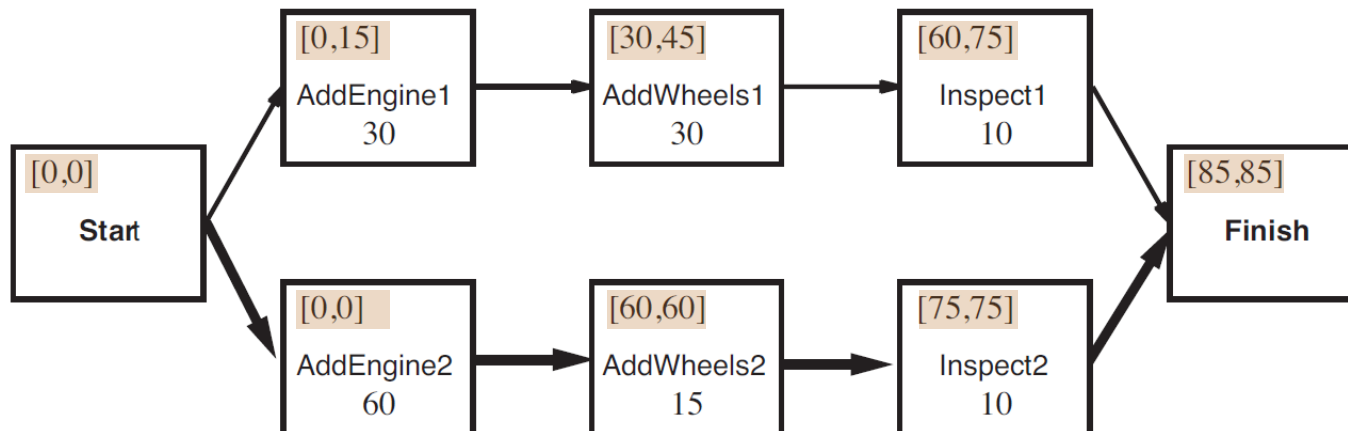
Razporejanje opravil

- delno urejen plan: vrstni red podmnožice aktivnosti je lahko urejen
- razširimo lahko notacijo (PDDL):
 - **Akcija1** < **Akcija2**: pomeni, da se mora Akcija1 zgoditi pred Akcijo2
 - **Resources** podaja števila razpoložljivih resursov
 - **DURATION** opredeljuje trajanje posamezne akcije
 - **CONSUME** opredeljuje (trajno) porabo določene količine resursov
 - **USE** opredeljuje (začasno) zasedenost količine resursov med izvajanjem akcije

```
Jobs (AddEngine1 < AddWheels1 < Inspect1,  
      AddEngine2 < AddWheels2 < Inspect2 )  
Resources (EngineHoists(1), WheelStations(1), Inspectors(2), LugNuts(500))  
  
Action (AddEngine1 , DURATION:30,  
        USE:EngineHoists(1))  
Action (AddEngine2 , DURATION:60,  
        USE:EngineHoists(1))  
Action (AddWheels1 , DURATION:30,  
        CONSUME:LugNuts(20), USE:WheelStations(1))  
Action (AddWheels2 , DURATION:15,  
        CONSUME:LugNuts(20), USE:WheelStations(1))  
Action (Inspect i, DURATION:10,  
        USE:Inspectors (1))
```

Razporejanje opravil

- za začetek: samo časovne omejitve
- **metoda kritične poti**
 - kritična pot: pot, ki je najdaljša in določa dolžino trajanja celotnega plana (krajšanje vzporednih poti ne vpliva na trajanje plana)
 - vsaki akciji priredimo par **[ES, LS]**:
 - **ES** – najbolj zgodnji možen začetek (angl. *Earliest Start*)
 - **LS** – najbolj pozni možen začetek (angl. *Latest Start*)



Razporejanje opravil

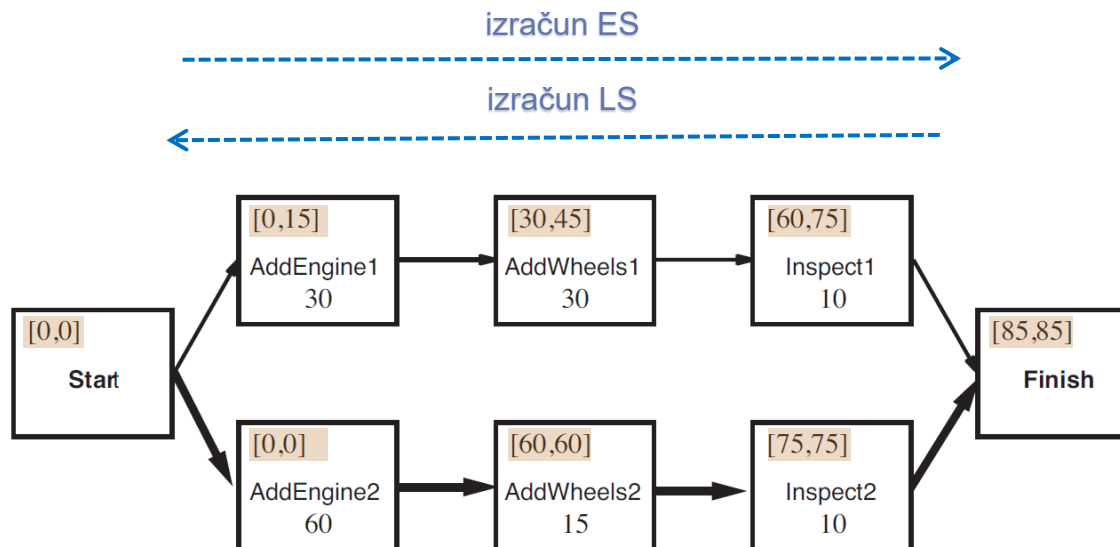

$$ES(Start) = 0$$

$$ES(B) = \max_{A < B} ES(A) + Duration(A)$$

$$LS(Finish) = ES(Finish)$$

$$LS(A) = \min_{A < B} LS(B) - Duration(A)$$


$$rezerva\ (slack) = LS - ES$$



- časovna zahtevnost algoritma: $O(Nb)$, N – število akcij, b – faktor vejanja

Razporejanje opravil

- dodatno: upoštevanje tudi resursov
- uvede **omejitev**, da se aktivnosti, ki potrebujeta iste resurse, ne smeta prekrivati



- sprememba časovne zahtevnosti: $O(Nb) \rightarrow$ NP-težek problem (!)
- primer izziv iz leta 1963 nerešen 23 let:
 - resursi: 10 strojev, 10 nalog, 100 akcij
 - preizkušene metode: simulirano ohlajanje, tabu search, razveji in omeji, ...
- primerna heuristika: algoritem **najmanjše časovne rezerve** (angl. *minimum slack algorithm*)
 - na vsaki iteraciji dodeli **najbolj zgodnji možen začetek** akciji, ki ima **izpolnjene vse predhodnike** in ima **najmanj časovne rezerve**,
 - nato posodobi [ES in LS] za celotni graf in ponovi.


Razporejanje opravil

Diskusija:

- Kakšen je rezultat simulacije algoritma najmanjše časovne rezerve na obravnavanem problemu?
- Ali je rešitev enaka optimalni? Zakaj?
- Kako upoštevati omejitve v zaporedju akcij pri pristopih za planiranje?
- Kako upoštevati omejitve v omejenem številu resursov?




Pregled



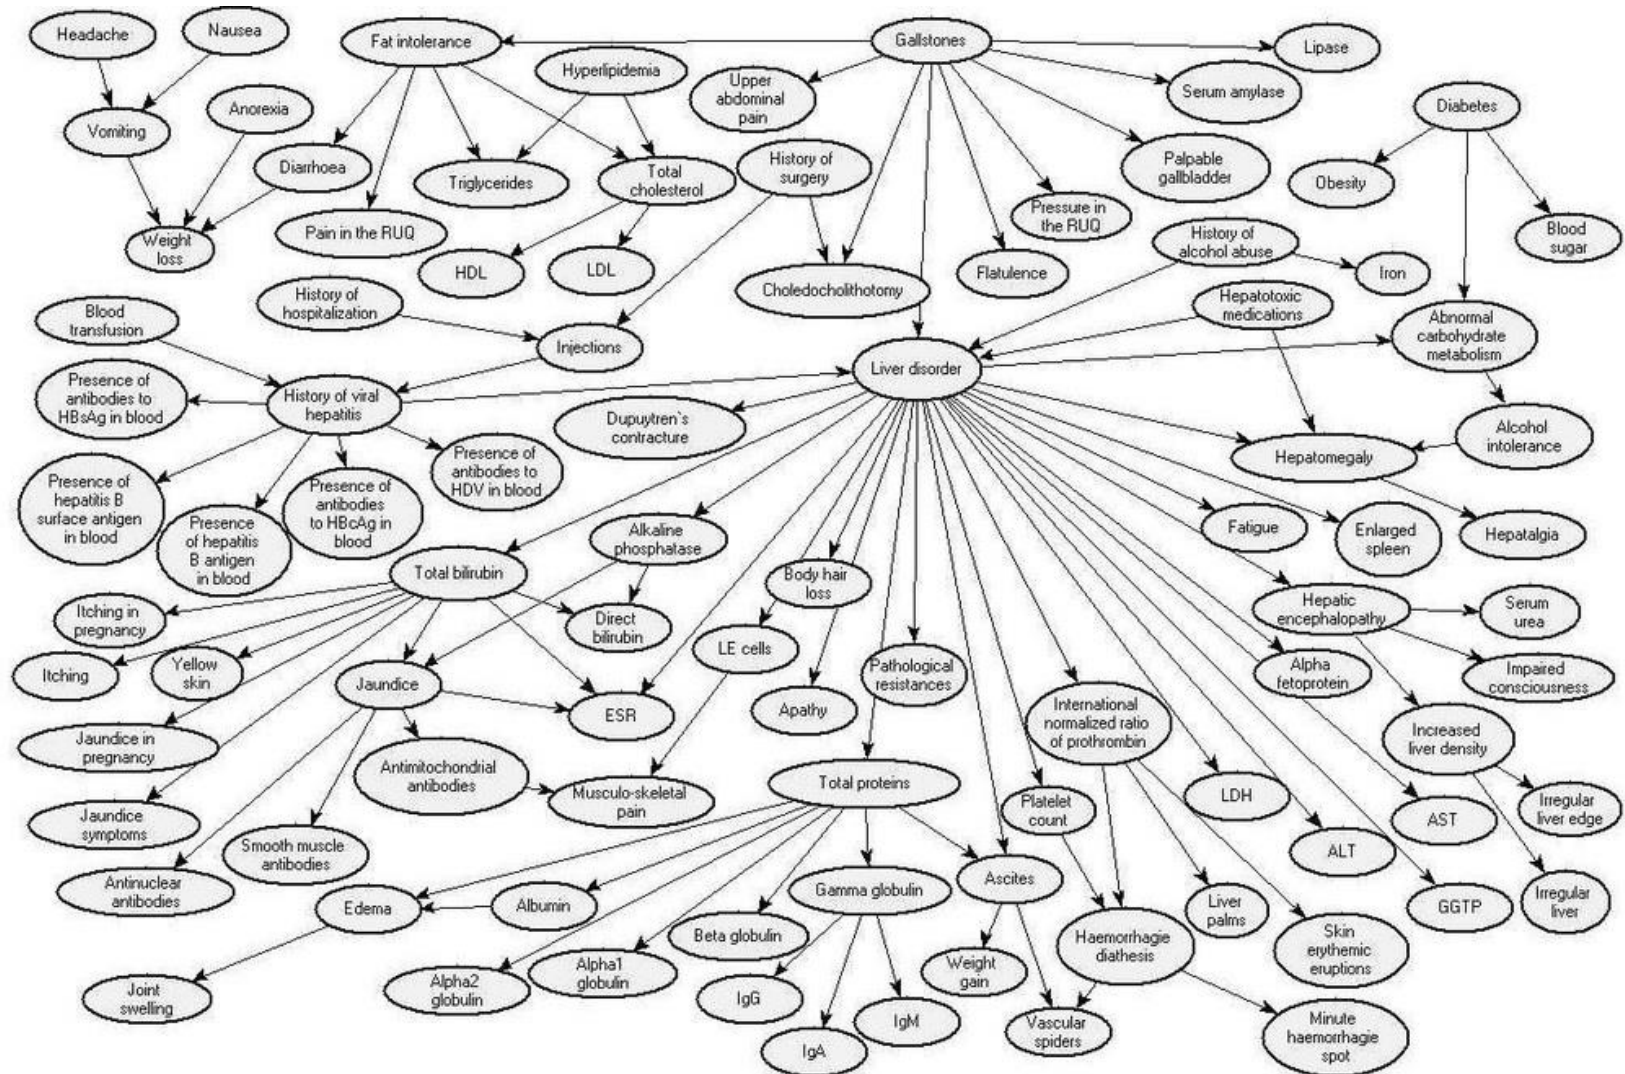
- planiranje
 - planiranje s "klasičnim" preiskovanjem prostora stanj
 - planiranje s sredstvi in cilji
 - planiranje z regresiranjem ciljev
 - razporejanje opravil
- bayesovske mreže
 - definicija
 - odvisnosti v bayesovski mreži
 - neodvisnosti v bayesovski mreži
 - verjetnostno sklepanje
 - ekvivalenca bayesovskih mrež

Bayesovske mreže

- so verjetnostni model, s katerim predstavimo **odvisnosti med slučajnimi spremenljivkami**
- pristop za **obravnavo negotovosti** v bazah znanja, ki je matematično dobro utemeljen v verjetnosti
- model je predstavljen z **usmerjenim acikličnim grafom**:
 - vozlišča: slučajne spremenljivke (dejstva, hipoteze),
 - povezave: odvisnosti med spremenljivkami (vpliv starša na naslednika)
- primeri uporabe:
 - splošno: za predstavitev verjetnostnega znanja in verjetnostno sklepanje
 - medicina: povezave med boleznijo in simptomi (diagnostika), napovedovanje izida operacije
 - ekspertni sistemi: ocenjevanje kvalitete vode, ...
 - sklepanje: kako verjetno so določene trditve, če vemo, da so druge trditve resnične?




Primer iz medicine



Bayesovske mreže

- stanje sveta povzamemo z **vektorjem (logičnih) spremenljivk**
- agent sklepa na **verjetnost** resničnosti določene spremenljivke
- upoštevamo lahko, da so določene spremenljivke med seboj neodvisne, kar predstavimo z bayesovsko mrežo, ki odraža te neodvisnosti (nepovezana vozlišča niso odvisna)
- primer:
 - senzor se sproži ob vlomu v hišo
 - včasih lahko tudi udar strele nehoteno sproži senzor
 - senzor ima nalogo, da sproži alarm in izvede opozorilni telefonski klic
- odvisnosti, ki izhajajo iz mreže:
 - senzor je odvisen od vloma in strele
 - alarm je odvisen od senzorja
 - klic je odvisen od senzorja



Bayesovske mreže

- z zapisom $P(X)$ okrajšamo $P(X = \text{true})$, z zapisom $P(XY)$ pa konjunkcijo
- za opis stanja sveta, ki ima n spremenljivk, bi morali poznati **popolno verjetnostno porazdelitev** ($2^n - 1$ podatkov – možnih stanj vseh logičnih spremenljivk)

- spremenljivke: V, St, Se, A, K
- popolna verjetnostna porazdelitev:

$$P(V St Se A K) = \dots$$


$$P(\sim V St Se A K) = \dots$$

$$P(V \sim St Se A K) = \dots$$

$$P(\sim V \sim St Se A K) = \dots$$

...

- potrebujemo $2^5 - 1 = 31$ verjetnosti
 - nepraktično ali nemogoče za veliko število spremenljivk
-
- verjetnost pojubnega dogodka (npr. $P(VK)$) izračunamo z vsoto vseh kombinacij vrednosti spremenljivk St, Se, A (pozitivna ali negirana) pri vrednostih $V = \text{true}$ in $K = \text{true}$.



Pogojne verjetnosti

- ker bayesovska mreža opredeljuje odvisnosti spremenljivk, lahko opredelimo problem samo s pogojnimi verjetnostmi:

$$P(vlom) = 0,001$$

$$P(strela) = 0,02$$

$$P(senzor \mid vlom \wedge strela) = 0,9$$

$$P(senzor \mid vlom \wedge \sim strela) = 0,9$$

$$P(senzor \mid \sim vlom \wedge strela) = 0,1$$


$$P(senzor \mid \sim vlom \wedge \sim strela) = 0,001$$

$$P(alarm \mid senzor) = 0,95$$

$$P(alarm \mid \sim senzor) = 0,001$$

$$P(klic \mid senzor) = 0,95$$

$$P(klic \mid \sim senzor) = 0$$



- podamo torej 10 podatkov namesto $2^5 - 1 = 31$
- za spremenljivke, ki niso med seboj odvisne, ne potrebujemo vseh kombinacij verjetnosti:
 - če sta X in Y **odvisna**, v splošnem velja $P(XY) = P(X) \cdot P(Y|X)$ (potrebujemo $P(Y|X)$)
 - če sta X in Y **neodvisna**, velja: $P(XY) = P(X) \cdot P(Y)$ ($P(Y|X)$ ne potrebujemo, ker zaradi neodvisnosti velja $P(Y|X) = P(Y)$)

Pogojne verjetnosti

- pogojne verjetnosti lahko predstavimo tudi s tabelami pogojnih verjetnosti

| $P(vlom)$ |
|-----------|
| 0,001 |

| $P(strela)$ |
|-------------|
| 0,02 |

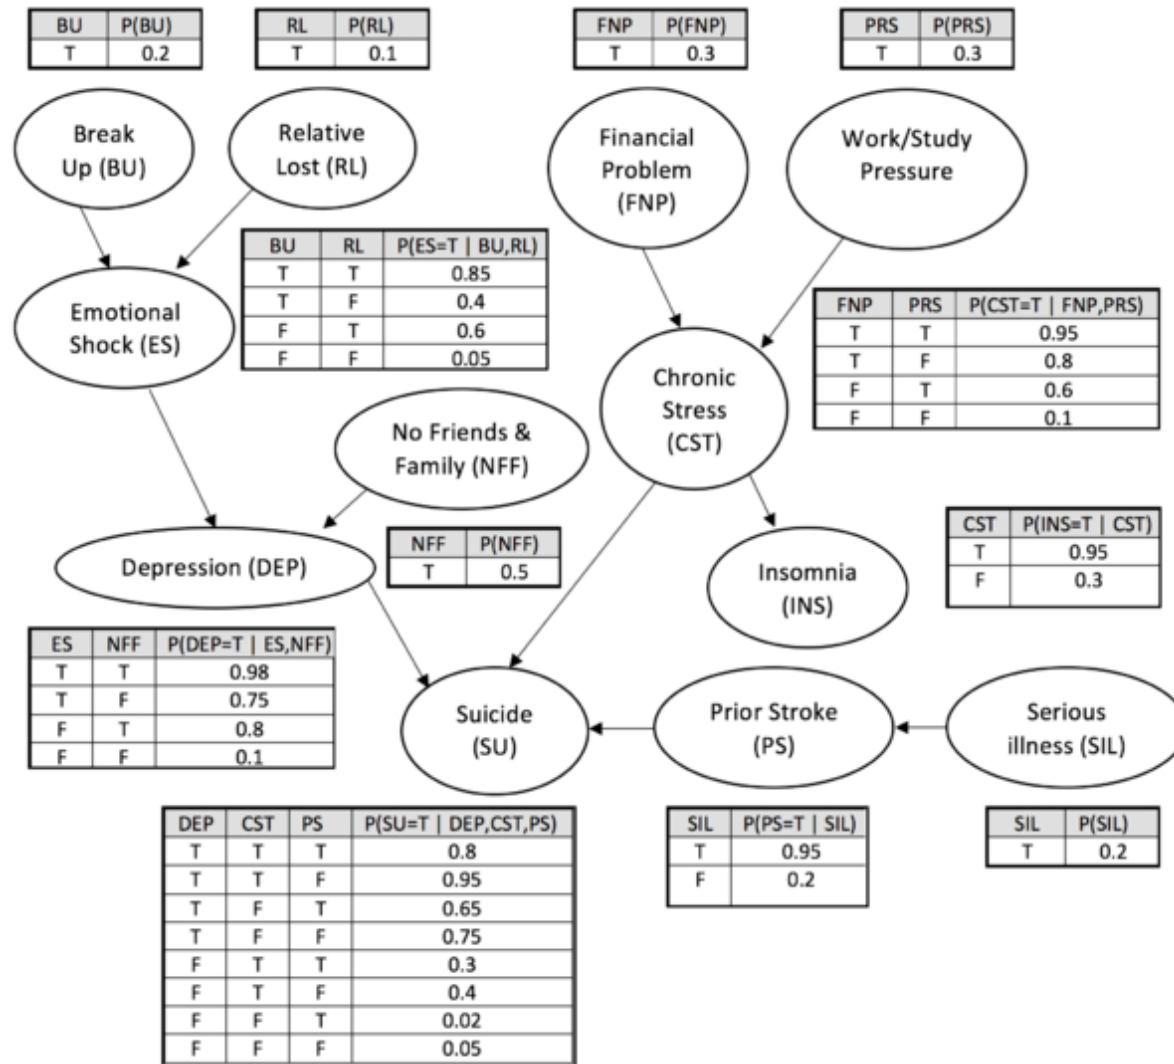
| $vlom$ | $strela$ | $P(senzor)$ |
|--------|----------|-------------|
| true | true | 0,9 |
| true | false | 0,9 |
| false | true | 0,1 |
| false | false | 0,001 |

| $senzor$ | $P(alarm)$ |
|----------|------------|
| true | 0,95 |
| false | 0,001 |

| $senzor$ | $P(klic)$ |
|----------|-----------|
| true | 0,95 |
| false | 0 |

- verjetnostni značaj modeliranja z bayesovskimi mrežami: vsota pogojnih verjetnosti $P(X|Y)$ in $P(X|\sim Y)$ ni enaka 1, kar nakazuje, da obstajajo za X tudi drugi, neopredeljeni razlogi, ki niso zajeti v predstavitvi problema s podano mrežo

Primer s podanimi verjetnostmi



Izračun verjetnosti dogodka

- s pogojnimi verjetnostmi **lahko izračunamo verjetnost dogodka** iz popolne verjetnostne porazdelitve

- primer: kakšna je verjetnost $P(V \sim St \ Se \ A \ K)$?

$$\begin{aligned} P(V \sim St \ Se \ A \ K) &= P(V) \cdot P(\sim St \ Se \ A \ K|V) = \\ &= P(V) \cdot P(\sim St | V) \cdot P(Se|V \sim St) \cdot P(A|V \sim St \ Se) \cdot P(K|V \sim St \ Se \ A) \end{aligned}$$

- zaradi neodvisnosti, podanih v mreži, velja:

$$P(\sim St|V) = P(\sim St)$$

$$P(A|V \sim St \ Se) = P(A|Se)$$


$$P(K|V \sim St \ Se \ A) = P(K|Se)$$

- torej:


$$\begin{aligned} P(V \sim St \ Se \ A \ K) &= P(V) \cdot P(\sim St \ Se \ A \ K|V) = \\ &= P(V) \cdot P(\sim St) \cdot P(Se|V \sim St) \cdot P(A|Se) \cdot P(K|Se) \\ &= 0,001 \cdot 0,98 \cdot 0,9 \cdot 0,95 \cdot 0,9 = 0,00075 \end{aligned}$$

- v splošnem velja:

$$P(X_1 X_2 \dots X_n) = \prod_{i=1}^n P(X_i | \text{starši}(X_i))$$




Pregled




- bayesovske mreže
 - definicija
 - odvisnosti v bayesovski mreži
 - neodvisnosti v bayesovski mreži
 - verjetnostno sklepanje
 - ekvivalenca bayesovskih mrež


Verjetnostno sklepanje




$$P(V | K) = ?$$




$$P(V | K St) = ?$$



$$P(V | A \sim St) = ?$$



$$P(A \sim K | V) = ?$$





$$P(V | St) = ?$$

- možni sta dve smeri sklepanja:
 - **vzročno** (od vzrokom k posledicam): npr. $P(A | V St) = ?$
 - **diagnostično** (od posledic k vzrokom): npr. $P(V | A) = ?$

Odvisnosti v mreži



- **skupni prednik:**

- *alarm* in *klic* sta **odvisna**; če vemo, da je eden od njiju resničen, vpliva to tudi na naše verjetje o resničnosti drugega (če se je sprožil alarm, se je verjetno izvedel tudi klic);
 $P(A|K) \neq P(A)$, $P(K|A) \neq P(K)$
- vendar: poznavanje resničnosti prednika *senzor* omogoči, da *alarm* in *klic* obravnavamo kot **neodvisna** (vemo, da se je sprožil *senzor*, torej se je z določeno verjetnostjo tudi sprožil *alarm* in z določeno (neodvisno) verjetnostjo izvedel tudi *klic*;
 $P(A|Se \wedge K) = P(A|Se)$, $P(K|Se \wedge A) = P(K|Se)$



- **skupni naslednik:**


- *vlom* in *strela* sta medseboj **neodvisna** (vedenje, da se je zgodil vlom, ne vpliva na verjetje o dogodku strele)
 $P(V|St) = P(V)$, $P(St|V) = P(St)$
- vendar: poznavanje resničnosti tega, da se je sprožil *senzor* povzroči, da dogodka *vlom* in *strela* postaneta **odvisna**; ker sta oba vzroka za sproženje *senzorja*, velja, da resničnost enega zmanjšuje verjetnost drugega in obratno




Odvisnosti v mreži

- **veriga**


- *vlom* in *alarm* sta **odvisna**; poznavanje resničnosti enega od njiju vpliva na naše verjetje o resničnosti drugega
- vendar: če vemo, da je resničen tudi *senzor*, postaneta *vlom* in *alarm* **neodvisna**: poznavanje resničnosti spremenljivke *alarm* ni pogojena s poznavanjem *vloma* in obratno
- pravimo, da vozlišče *senzor* *blokira* vpliv vozlišča *vlom* na vozlišče *alarm*




- pravilo lahko posplošimo na daljše verige:



Vaja




- podana je naslednja bayesovska mreža:



- a in c naj bosta redka dogodka in vse povezave v mreži naj predstavljajo vzročnost med dogodki (torej npr. $P(b|a) \gg P(b|\sim a)$). Brez računanja oceni relacije ($<$, $>$ ali $=$) med naslednjimi verjetnostmi:
 - a) $P(a) : P(a|c)$
 - b) $P(a) : P(a|d)$
 - c) $P(a|d) : P(a|cd)$
 - d) $P(d|bc) : P(d|abc)$

Primer

- podobno sklepanje lahko uporabimo na našem primeru:
 - vlom je sam po sebi malo verjeten dogodek
 - denimo, da prejmemo opozorilni klic
 - zaradi prejetega klica se verjetnost proženja senzorja poveča (in ravno tako verjetnost alarma)
 - ker vlom sproža senzor, se poveča tudi verjetnost vlomu
 - ali: izvemo, da je doma bila nevihta s strelami; ker je strela možen vzrok za proženje senzorja, se verjetnost vloma zmanjša





**Bayesovske mreže:
odvisnosti, sklepanje**